

如果提供适当的归属，Google 特此授权复制本文中的表格和图形，仅供新闻或学术作品使用。

您所需要的就是关注

Ashish Vaswani* Google 大脑 avaswani@google.com

诺姆·沙泽尔* Google Brain noam@google.com

尼基·帕尔玛* Google 研究 nikip@google.com

Jakob Uszkoreit* Google 研究 uszkoreit@google.com

Llion Jones* Google 研究 llion@google.com

艾丹·N·戈麦斯*[†] 多伦多大学 aidan@cs.toronto.edu

ukasz Kaiser* Google 大脑 lukaszkaizer@google.com

伊利亚·波洛苏欣*[‡] illia.polosukhin@gmail.com

抽象的

主要序列转导模型基于复杂的循环或卷积神经网络，包括编码器和解码器。性能最好的模型还通过注意力机制连接编码器和解码器。我们提出了一种新的简单网络架构——Transformer，它完全基于注意力机制，完全不需要递归和卷积。对两个机器翻译任务的实验表明，这些模型具有卓越的质量，同时具有更高的并行性，并且需要的训练时间显著减少。我们的模型在 WMT 2014 英语到德语翻译任务中取得了 28.4 BLEU，比现有的最佳结果（包括集成）提高了 2 BLEU 以上。在 WMT 2014 英法翻译任务中，我们的模型在 8 个 GPU 上训练 3.5 天后，建立了新的单模型最先进 BLEU 分数 41.8，这只是文献中最佳模型训练成本的一小部分。我们通过将 Transformer 成功应用于具有大量和有限训练数据的英语选区解析，证明 Transformer 可以很好地推广到其他任务。

*Equal contribution. Listing order is random. Jakob proposed replacing RNNs with self-attention and started the effort to evaluate this idea. Ashish, with Illia, designed and implemented the first Transformer models and has been crucially involved in every aspect of this work. Noam proposed scaled dot-product attention, multi-head attention and the parameter-free position representation and became the other person involved in nearly every detail. Niki designed, implemented, tuned and evaluated countless model variants in our original codebase and tensor2tensor. Llion also experimented with novel model variants, was responsible for our initial codebase, and efficient inference and visualizations. Lukasz and Aidan spent countless long days designing various parts of and implementing tensor2tensor, replacing our earlier codebase, greatly improving results and massively accelerating our research.

[†]Work performed while at Google Brain.

[‡]Work performed while at Google Research.

1 简介

循环神经网络，特别是长短期记忆[13]和门控循环[7]神经网络，已被牢固地确立为序列建模和转导问题（例如语言建模和机器翻译）中最先进的方法[35,2,5]。此后，人们做出了许多努力，不断突破循环语言模型和编码器-解码器架构的界限[38,24,15]。

循环模型通常会沿着输入和输出序列的符号位置进行计算。将位置与计算时间中的步骤对齐，它们生成一系列隐藏状态 h_t ，作为先前隐藏状态 h_{t-1} 和位置 t 输入的函数。这种固有的顺序性质阻碍了训练示例中的并行化，这在较长的序列长度上变得至关重要，因为内存限制限制了示例之间的批处理。最近的工作通过分解技巧 [21] 和条件计算 [32] 显著提高了计算效率，同时还提高了后者的模型性能。然而，顺序计算的基本限制仍然存在。

注意力机制已经成为各种任务中引人注目的序列建模和转导模型的一个组成部分，允许对依赖关系进行建模，而不考虑它们在输入或输出序列中的距离[2, 19]。然而，除了少数情况外[27]，这种注意力机制都是与循环网络结合使用的。

在这项工作中，我们提出了 Transformer，这是一种避免重复的模型架构，而是完全依赖注意力机制来绘制输入和输出之间的全局依赖关系。Transformer 允许显著提高并行度，并且在 8 个 P100 GPU 上进行短短 12 小时的训练后，可以在翻译质量方面达到新的水平。

2 背景

减少顺序计算的目标也构成了扩展神经 GPU [16]、ByteNet [18] 和 ConvS2S [9] 的基础，所有这些都使用卷积神经网络作为基本构建块，并行计算所有输入和输出位置的隐藏表示。在这些模型中，关联来自两个任意输入或输出位置的信号所需的操作数量随着位置之间的距离而增加，对于 ConvS2S 呈线性增长，对于 ByteNet 呈对数增长。这使得学习遥远位置之间的依赖关系变得更加困难[12]。在 Transformer 中，这被减少到恒定数量的操作，尽管由于平均注意力加权位置而导致有效分辨率降低，我们用多头注意力来抵消这种影响，如第 3.2 节所述。

自注意力（有时称为内部注意力）是一种将单个序列的不同位置相关联的注意力机制，以便计算序列的表示。自注意力已成功应用于各种任务，包括阅读理解、抽象概括、文本蕴涵和学习任务无关的句子表示[4,27,28,22]。

端到端记忆网络基于循环注意机制而不是序列对齐循环，并且已被证明在简单语言问答和语言建模任务上表现良好[34]。

然而，据我们所知，Transformer 是第一个完全依赖自注意力来计算其输入和输出表示而不使用序列对齐 RNN 或卷积的转换模型。在接下来的章节中，我们将描述 Transformer，激发 self-attention 并讨论其相对于 [17, 18] 和 [9] 等模型的优势。

3 模型架构

大多数竞争性神经序列转导模型都具有编码器-解码器结构 [5,2,35]。这里，编码器将符号表示的输入序列 (x_1, \dots, x_n) 映射到连续表示的序列 $\mathbf{z} = (z_1, \dots, z_n)$ 。给定 \mathbf{z} ，解码器然后生成符号的输出序列 (y_1, \dots, y_m) ，一次一个元素。在每个步骤中，模型都是自回归的[10]，在生成下一个时将先前生成的符号用作附加输入。

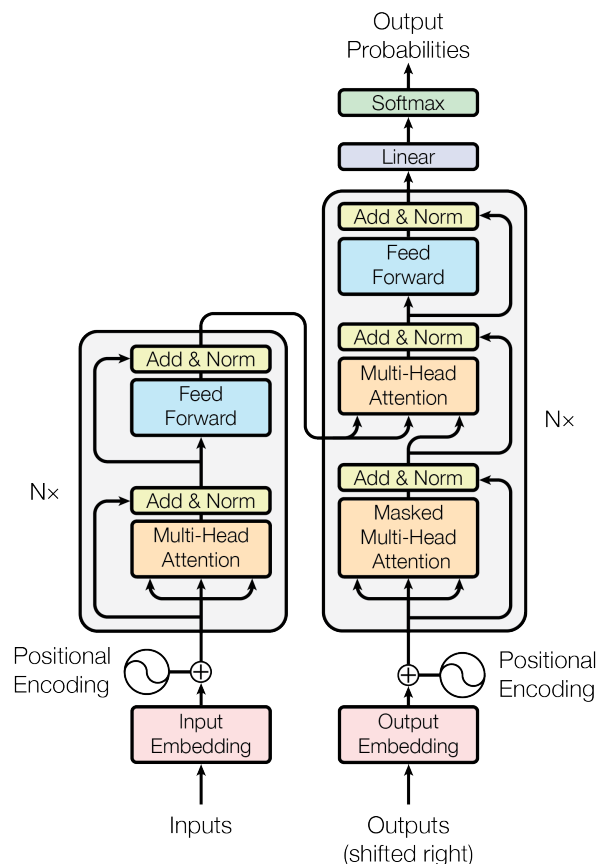


图 1: Transformer - 模型架构。

Transformer 遵循这一整体架构，对编码器和解码器使用堆叠自注意力和逐点、全连接层，分别如图 1 的左半部分和右半部分所示。

3.1 编码器和解码器堆栈

编码器：编码器由 $N = 6$ 个相同层的堆栈组成。每层有两个子层。第一个是多头自注意力机制，第二个是简单的、位置明智的全连接前馈网络。我们在两个子层周围采用残差连接[11]，然后进行层归一化[1]。即每个子层的输出为 $\text{LayerNorm}(x + \text{Sublayer}(x))$ ，其中 $\text{Sublayer}(x)$ 是子层本身实现的函数。为了促进这些残差连接，模型中的所有子层以及嵌入层都会产生维度为 $d_{\text{model}} = 512$ 的输出。

解码器：解码器也是由 $N = 6$ 个相同层的堆栈组成。除了每个编码器层中的两个子层之外，解码器还插入第三个子层，该子层对编码器堆栈的输出执行多头关注。与编码器类似，我们在每个子层周围采用残差连接，然后进行层归一化。我们还修改了解码器堆栈中的自注意力子层，以防止位置关注后续位置。这种掩蔽与输出嵌入偏移一个位置的事实相结合，确保位置 i 的预测只能依赖于小于 i 的位置处的已知输出。

3.2 注意事项

注意力函数可以描述为将查询和一组键值对映射到输出，其中查询、键、值和输出都是向量。输出被计算为加权和




图 2：（左）缩放的点积注意力。（右）多头注意力由多个并行运行的注意力层组成。

值的权重，其中分配给每个值的权重是通过查询与相应键的兼容性函数计算的。

3.2.1 缩放点积注意力

我们将我们的特别注意力称为“缩放点积注意力”（图 2）。输入由维度 d_k 的查询和键以及维度 d_v 的值组成。我们使用所有键计算查询的点积，将每个键除以 $\sqrt{d_k}$ ，然后应用 softmax 函数来获取值的权重。

在实践中，我们同时计算一组查询的注意力函数，并将它们打包成一个矩阵 Q 。键和值也一起打包成矩阵 K 和 V 。我们将输出矩阵计算为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (1)$$

两种最常用的注意力函数是加性注意力[2]和点积（乘法）注意力。除了 $\frac{1}{\sqrt{d_k}}$ 的缩放因子之外，点积注意力与我们的算法相同。附加注意力使用具有单个隐藏层的前馈网络来计算兼容性函数。虽然两者在理论复杂性上相似，但点积注意力在实践中更快、更节省空间，因为它可以使用高度优化的矩阵乘法代码来实现。

虽然对于较小的 d_k 值，两种机制的表现相似，但加性注意力优于点积注意力，而无需针对较大的 d_k 值进行缩放[3]。我们怀疑，对于较大的 d_k 值，点积的幅度会变大，从而将 softmax 函数推入梯度极小的区域⁴。为了抵消这种影响，我们将点积缩放 $\frac{1}{\sqrt{d_k}}$ 。

3.2.2 多头注意力

我们发现，使用不同的学习线性投影分别将查询、键和值线性投影到 d_k 、 d_k 和 d_v 维度 h 次，而不是使用 d_{model} 维度的键、值和查询来执行单个注意函数。然后，我们对查询、键和值的每个投影版本并行执行注意力函数，产生 d_v 维

⁴To illustrate why the dot products get large, assume that the components of q and k are independent random variables with mean 0 and variance 1. Then their dot product, $q \cdot k = \sum_{i=1}^{d_k} q_i k_i$, has mean 0 and variance d_k .

输出值。将它们连接并再次投影，得到最终值，如图 2 所示。

多头注意力允许模型共同关注来自不同位置的不同表示子空间的信息。对于单一注意力头，平均会抑制这种情况。

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

$$\text{where head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

其中投影是参数矩阵 $W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$ 、 $W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$ 、 $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ 和 $W^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$ 。

在这项工作中，我们采用 $h = 8$ 个并行注意力层或头。对于每一个，我们都使用 $d_k = d_v = d_{\text{model}}/h = 64$ 。由于每个头的维度减少，总计算成本与全维度的单头注意力相似。

3.2.3 模型中注意力的应用

Transformer 以三种不同的方式使用多头注意力：

- 在“编码器-解码器注意”层中，查询来自先前的解码器层，并且内存键和值来自编码器的输出。这允许解码器中的每个位置都参与输入序列中的所有位置。这模仿了序列到序列模型中典型的编码器-解码器注意机制，例如[38,2,9]。
- 编码器包含自注意力层。在自注意力层中，所有键、值和查询都来自同一位置，在本例中是编码器中前一层的输出。编码器中的每个位置可以关注编码器上一层中的所有位置。
- 类似地，解码器中的自注意力层允许解码器中的每个位置关注解码器中直到并包括该位置的所有位置。我们需要防止解码器中的左向信息流以保留自回归属性。我们通过屏蔽（设置为 $-\infty$ ）softmax 输入中与非法连接相对应的所有值，在缩放点积注意力内部实现这一点。参见图 2。

3.3 位置式前馈网络

除了注意力子层之外，我们的编码器和解码器中的每个层都包含一个完全连接的前馈网络，该网络单独且相同地应用于每个位置。这由两个线性变换组成，中间有一个 ReLU 激活。

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (2)$$

虽然不同位置的线性变换是相同的，但它们在层与层之间使用不同的参数。另一种描述方式是内核大小为 1 的两个卷积。输入和输出的维度为 $d_{\text{model}} = 512$ ，内层的维度为 $d_{\text{ff}} = 2048$ 。

3.4 嵌入和Softmax

与其他序列转导模型类似，我们使用学习嵌入将输入标记和输出标记转换为维度 d_{model} 的向量。我们还使用通常学习的线性变换和 softmax 函数将解码器输出转换为预测的下一个令牌概率。在我们的模型中，我们在两个嵌入层和 pre-softmax 线性变换之间共享相同的权重矩阵，类似于[30]。在嵌入层中，我们将这些权重乘以 $\sqrt{d_{\text{model}}}$

表 1: 不同层类型的最大路径长度、每层复杂度和最小顺序操作数。 n 是序列长度, d 是表示维度, k 是卷积核大小, r 是受限自注意力中邻域的大小。

Layer Type	Complexity per Layer	Sequential Operations	Maximum Path Length
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k(n))$
Self-Attention (restricted)	$O(r \cdot n \cdot d)$	$O(1)$	$O(n/r)$

3.5 位置编码

由于我们的模型不包含递归和卷积, 为了使模型能够利用序列的顺序, 我们必须注入一些有关序列中标记的相对或绝对位置的信息。为此, 我们将“位置编码”添加到编码器和解码器堆栈底部的输入嵌入中。位置编码与嵌入具有相同的维度 d_{model} , 因此可以将两者相加。位置编码有多种选择, 有学习的和固定的[9]。

在这项工作中, 我们使用不同频率的正弦和余弦函数:

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{\text{model}}})$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{\text{model}}})$$

其中 pos 是位置, i 是维度。也就是说, 位置编码的每个维度对应于正弦曲线。波长形成从 2π 到 $10000 \cdot 2\pi$ 的几何级数。我们选择这个函数是因为我们假设它可以让模型轻松学习关注相对位置, 因为对于任何固定偏移量 k , PE_{pos+k} 可以表示为 PE_{pos} 的线性函数。

我们还尝试使用学习的位置嵌入 [9], 发现这两个版本产生几乎相同的结果 (参见表 3 行 (E))。我们选择正弦版本, 因为它可以允许模型推断出比训练期间遇到的序列长度更长的序列长度。

4 为什么要自我关注

在本节中, 我们将自注意力层的各个方面与循环层和卷积层进行比较, 该循环层和卷积层通常用于将一个可变长度的符号表示序列 (x_1, \dots, x_n) 映射到另一个等长序列 (z_1, \dots, z_n) , 即 $x_i, z_i \in \mathbb{R}^d$, 例如典型序列转导编码器或解码器中的隐藏层。为了激发我们使用自我注意力, 我们考虑了三个需求。

一是每层的总计算复杂度。另一个是可以并行化的计算量, 以所需的最小顺序操作数来衡量。

第三个是网络中远程依赖之间的路径长度。学习远程依赖性在许多序列转导任务中的一个关键挑战。影响学习这种依赖性的能力的一个关键因素是前向和后向信号在网络中必须经过的路径的长度。输入和输出序列中的任意位置组合之间的路径越短, 学习远程依赖关系就越容易[12]。因此, 我们还比较了由不同层类型组成的网络中任意两个输入和输出位置之间的最大路径长度。

如表 1 所示, 自注意力层通过恒定数量的顺序执行操作连接所有位置, 而循环层需要 $O(n)$ 顺序操作。就计算复杂度而言, 当序列

长度 n 小于表示维度 d ，这最常见于机器翻译中最先进模型使用的句子表示，例如单词片段 [38] 和字节对 [31] 表示。为了提高涉及很长序列的任务的计算性能，自注意力可以限制为仅考虑输入序列中以相应输出位置为中心的大小为 r 的邻域。这会将最大路径长度增加到 $O(n/r)$ 。我们计划在未来的工作中进一步研究这种方法。

内核宽度为 $k < n$ 的单个卷积层不会连接所有输入和输出位置对。这样做需要在连续内核的情况下使用一堆 $O(n/k)$ 卷积层，或者在扩张卷积的情况下使用 $O(\log_k(n))$ [18]，从而增加网络中任意两个位置之间的最长路径的长度。卷积层通常比循环层昂贵 k 倍。然而，可分离卷积 [6] 大大降低了复杂性，达到 $O(k \cdot n \cdot d + n \cdot d^2)$ 。然而，即使使用 $k = n$ ，可分离卷积的复杂性也等于自注意力层和逐点前馈层的组合，这是我们在模型中采用的方法。

作为附带好处，自注意力可以产生更多可解释的模型。我们检查模型中的注意力分布，并在附录中展示和讨论示例。个体注意力头不仅清楚地学习执行不同的任务，而且许多注意力头似乎表现出与句子的句法和语义结构相关的行为。

5 培训

本节描述我们模型的训练制度。

5.1 训练数据和批处理

我们使用标准 WMT 2014 英语-德语数据集进行训练，该数据集包含约 450 万个句子对。句子使用字节对编码 [3] 进行编码，该编码具有约 37000 个标记的共享源-目标词汇表。对于英语-法语，我们使用了更大的 WMT 2014 英语-法语数据集，该数据集由 3600 万个句子组成，并将标记拆分为 32000 个单词片段词汇表 [38]。句子对按大致序列长度分批在一起。每个训练批次包含一组句子对，其中包含大约 25000 个源标记和 25000 个目标标记。

5.2 硬件和时间表

我们在一台配备 8 个 NVIDIA P100 GPU 的机器上训练我们的模型。对于我们使用整篇论文中描述的超参数的基本模型，每个训练步骤大约需要 0.4 秒。我们对基础模型进行了总计 100,000 步或 12 小时的训练。对于我们的大型模型（如表 3 的底线所述），步长时间为 1.0 秒。大模型接受了 300,000 步（3.5 天）的训练。

5.3 优化器

我们使用 Adam 优化器 [20] 和 $\beta_1 = 0.9$ 、 $\beta_2 = 0.98$ 和 $\epsilon = 10^{-9}$ 。我们根据以下公式在训练过程中改变学习率：

$$lr_{rate} = d_{\text{model}}^{-0.5} \cdot \min(step_num^{-0.5}, step_num \cdot warmup_steps^{-1.5}) \quad (3)$$

这对应于第一个 $warmup_steps$ 训练步骤的学习率线性增加，然后与步骤数的平方根倒数成比例地减少。我们使用了 $warmup_steps = 4000$ 。

5.4 正则化

我们在训练期间采用三种类型的正则化：

表 2: 在 2014 年英语到德语和英语到法语 newstest2014 测试中, Transformer 比之前最先进的模型获得了更好的 BLEU 分数, 而训练成本仅为一小部分。

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	41.29	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	$3.3 \cdot 10^{18}$	
Transformer (big)	28.4	41.8	$2.3 \cdot 10^{19}$	

残差 Dropout 我们将 dropout [33] 应用于每个子层的输出, 然后将其添加到子层输入并进行归一化。此外, 我们将 dropout 应用于编码器和解码器堆栈中的嵌入和位置编码的总和。对于基本模型, 我们使用的速率为 $P_{drop} = 0.1$ 。

标签平滑 在训练期间, 我们采用了值 $\epsilon_{ls} = 0.1$ [36] 的标签平滑。这会降低模型的困惑度, 因为模型会变得更加不确定, 但会提高准确性和 BLEU 分数。

6 个结果

6.1 机器翻译

在 WMT 2014 英语到德语翻译任务中, 大型 Transformer 模型 (表 2 中的 Transformer (big)) 比之前报告的最佳模型 (包括集成) 性能高出 2.0 BLEU 以上, 建立了新的最先进的 BLEU 分数 28.4。该模型的配置列于表 3 的最后一行。在 8 个 P100 GPU 上训练花费了 3.5 天。甚至我们的基础模型也超越了之前发布的所有模型和集成, 而训练成本只是任何竞争模型的一小部分。

在 WMT 2014 英法翻译任务中, 我们的大模型获得了 41.0 的 BLEU 分数, 优于之前发布的所有单一模型, 且训练成本不到之前最先进模型的 1/4。针对英语到法语训练的 Transformer (大) 模型使用了 dropout 率 $P_{drop} = 0.1$, 而不是 0.3。

对于基本模型, 我们使用通过对最后 5 个检查点进行平均而获得的单个模型, 这些检查点以 10 分钟的间隔写入。对于大型模型, 我们对最后 20 个检查点进行了平均。我们使用波束搜索, 波束大小为 4, 长度惩罚为 $\alpha = 0.6$ [38]。这些超参数是在开发集上进行实验后选择的。我们将推理期间的最大输出长度设置为输入长度 + 50, 但尽可能提前终止 [38]。

表 2 总结了我们的结果, 并将我们的翻译质量和训练成本与文献中的其他模型架构进行了比较。我们通过将训练时间、使用的 GPU 数量以及每个 GPU 持续单精度浮点容量的估计值相乘来估计用于训练模型的浮点运算数量⁵。

6.2 模型变化

为了评估 Transformer 不同组件的重要性, 我们以不同的方式改变了我们的基本模型, 测量了英语到德语翻译的性能变化

⁵We used values of 2.8, 3.7, 6.0 and 9.5 TFLOPS for K80, K40, M40 and P100, respectively.

表 3: Transformer 架构的变化。未列出的值与基本型号的值相同。所有指标均来自英德翻译开发集 newstest2013。根据我们的字节对编码, 列出的困惑度是每个单词的困惑度, 不应与每个单词的困惑度进行比较。

	N	d_{model}	d_{ff}	h	d_k	d_v	P_{drop}	ϵ_{ls}	train steps	PPL (dev)	BLEU (dev)	params $\times 10^6$		
base	6	512	2048	8	64	64	0.1	0.1	100K	4.92	25.8	65		
(A)					1	512	512				5.29	24.9		
					4	128	128				5.00	25.5		
					16	32	32				4.91	25.8		
					32	16	16				5.01	25.4		
(B)					16					5.16	25.1	58		
					32					5.01	25.4	60		
(C)	2									6.11	23.7	36		
	4									5.19	25.3	50		
	8									4.88	25.5	80		
		256					32	32				5.75	24.5	28
		1024					128	128				4.66	26.0	168
			1024									5.12	25.4	53
			4096									4.75	26.2	90
(D)							0.0				5.77	24.6		
							0.2				4.95	25.5		
								0.0		4.67	25.3			
								0.2		5.47	25.7			
(E)	positional embedding instead of sinusoids									4.92	25.7			
big	6	1024	4096	16				0.3	300K	4.33	26.4	213		

开发集, newstest2013。我们使用了上一节中描述的波束搜索, 但没有检查点平均。我们在表 3 中列出了这些结果。

在表 3 行 (A) 中, 我们改变注意力头的数量以及注意力键和值维度, 保持计算量恒定, 如第 3.2.2 节所述。虽然单头注意力比最佳设置差 0.9 BLEU, 但头数过多质量也会下降。

在表 3 行 (B) 中, 我们观察到减少注意力键大小 d_k 会损害模型质量。这表明确定兼容性并不容易, 并且比点积更复杂的兼容性函数可能是有益的。我们在 (C) 和 (D) 行中进一步观察到, 正如预期的那样, 模型越大越好, 并且 dropout 对于避免过度拟合非常有帮助。在行 (E) 中, 我们用学习的位置嵌入替换正弦位置编码 [9], 并观察到与基本模型几乎相同的结果。

6.3 英语选区解析

为了评估 Transformer 是否可以推广到其他任务, 我们对英语选区解析进行了实验。这项任务提出了具体的挑战: 输出受到强大的结构约束, 并且明显长于输入。此外, RNN 序列到序列模型尚未能够在小数据情况下获得最先进的结果 [37]。

我们在 Penn Treebank 的《华尔街日报》(WSJ) 部分 [25] 上用 $d_{\text{model}} = 1024$ 训练了一个 4 层 Transformer, 大约有 40K 训练句子。我们还在半监督环境中对其进行了训练, 使用了更大的高置信度和 BerkleyParser 语料库, 其中包含大约 1700 万个句子 [37]。我们在仅《华尔街日报》设置中使用了 16K 个标记的词汇表, 在半监督设置中使用了 32K 个标记的词汇表。

我们仅进行了少量实验来选择第 22 节开发集上的 dropout、注意力和残差 (第 5.4 节)、学习率和波束大小, 所有其他参数与英语到德语的基础翻译模型保持不变。在推理过程中, 我们

表 4: Transformer 很好地推广了英语选区解析 (结果见《华尔街日报》第 23 节)

Parser	Training	WSJ 23 F1
Vinyals & Kaiser et al. (2014) [37]	WSJ only, discriminative	88.3
Petrov et al. (2006) [29]	WSJ only, discriminative	90.4
Zhu et al. (2013) [40]	WSJ only, discriminative	90.4
Dyer et al. (2016) [8]	WSJ only, discriminative	91.7
Transformer (4 layers)	WSJ only, discriminative	91.3
Zhu et al. (2013) [40]	semi-supervised	91.3
Huang & Harper (2009) [14]	semi-supervised	91.3
McClosky et al. (2006) [26]	semi-supervised	92.1
Vinyals & Kaiser et al. (2014) [37]	semi-supervised	92.1
Transformer (4 layers)	semi-supervised	92.7
Luong et al. (2015) [23]	multi-task	93.0
Dyer et al. (2016) [8]	generative	93.3

将最大输出长度增加到输入长度 + 300。对于仅 WSJ 和半监督设置, 我们使用了 21 的波束大小和 $\alpha = 0.3$ 。

表 4 中的结果表明, 尽管缺乏特定于任务的调整, 我们的模型表现得令人惊讶地好, 比之前报告的所有模型 (循环神经网络语法除外) [8] 产生了更好的结果。

与 RNN 序列到序列模型 [37] 相比, 即使仅在 WSJ 40K 句子训练集上进行训练, Transformer 的性能也优于 Berkeley-Parser [29]。

7 结论

在这项工作中, 我们提出了 Transformer, 这是第一个完全基于注意力的序列转换模型, 用多头自注意力取代了编码器-解码器架构中最常用的循环层。

对于翻译任务, Transformer 的训练速度明显快于基于循环层或卷积层的架构。在 WMT 2014 英语-德语和 WMT 2014 英语-法语翻译任务中, 我们都达到了新的最先进水平。在前一项任务中, 我们最好的模型甚至优于所有先前报告的集成。

我们对基于注意力的模型的未来感到兴奋, 并计划将其应用于其他任务。我们计划将 Transformer 扩展到涉及文本以外的输入和输出模式的问题, 并研究局部的、受限的注意力机制, 以有效地处理图像、音频和视频等大型输入和输出。减少一代的顺序是我们的另一个研究目标。

我们用于训练和评估模型的代码可在 <https://github.com/tensorflow/tensor2tensor> 上找到。

致谢 我们感谢 Nal Kalchbrenner 和 Stephan Gouws 富有成效的评论、更正和启发。

参考

- [1] 吉米·雷巴、杰米·瑞安·基罗斯和杰弗里·E·辛顿。层标准化。 *arXiv preprint arXiv:1607.06450*, 2016 年。[2] Dzmitry Bahdanau, Kyunghyun Cho 和 Yoshua Bengio。通过共同学习对齐和翻译来进行神经机器翻译。 *CoRR*, abs/1409.0473, 2014。[3] Denny Brietz, Anna Goldie, Minh-Thang Luong 和 Quoc V. Le。对神经机器翻译架构的大规模探索。 *CoRR*, abs/1703.03906, 2017。[4] 程建鹏, 董立, 米雷拉·拉帕塔。用于机器阅读的长短期记忆网络。 *arXiv preprint arXiv:1601.06733*, 2016。

- [5] Kyunghyun Cho, Bart van Merriënboer, Çağlar Gulcehre, Fethi Bougares, Holger Schwenk 和 Yoshua Bengio。使用 rnn 编码器-解码器学习短语表示以进行统计机器翻译。 *CoRR*, abs/1406.1078, 2014。
- [6] 弗朗索瓦·乔莱。Xception: 具有深度可分离卷积的深度学习。 *arXiv preprint arXiv:1610.02357*, 2016 年。
- [7] Junyoung Chung, Çağlar Gülçehre, Kyunghyun Cho 和 Yoshua Bengio。门控循环神经网络对序列建模的实证评估。 *CoRR*, abs/1412.3555, 2014。
- [8] 克里斯·戴尔、阿迪古纳·昆科罗、米格尔·巴列斯特罗斯和诺亚·A·史密斯。递归神经网络语法。在 *Proc. of NAACL*, 2016 年。
- [9] 乔纳斯·格林、迈克尔·奥利、大卫·格兰吉尔、丹尼斯·亚拉茨和扬·N·多芬。卷积序列到序列学习。 *arXiv preprint arXiv:1705.03122v2*, 2017 年。
- [10] 亚历克斯·格雷夫斯。使用循环神经网络生成序列。 *arXiv preprint arXiv:1308.0850*, 2013。
- [11] 何凯明, 张翔宇, 任少清, 孙健。用于图像识别的深度残差学习。 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 第 770-778 页, 2016 年。
- [12] Sepp Hochreiter, Yoshua Bengio, Paolo Frasconi 和 Jürgen Schmidhuber。循环网络中的梯度流: 学习长期依赖性的困难, 2001 年。
- [13] 塞普·霍赫赖特和于尔根·施米德胡贝尔。长短期记忆。 *Neural computation*, 9(8): 1735-1780, 1997。
- [14] 黄忠强, 玛丽·哈珀。具有跨语言潜在注释的自训练 PCFG 语法。在 *Proceedings of the 2009 Conference on Empirical Methods in Natural Language Processing*, 第 832-841 页。ACL, 2009 年 8 月。
- [15] Rafal Jozefowicz, Oriol Vinyals, Mike Schuster, Noam Shazeer 和 Yonghui Wu。探索语言建模的局限性。 *arXiv preprint arXiv:1602.02410*, 2016。
- [16] 武卡斯·凯撒和萨米·本吉奥。主动记忆可以取代注意力吗? 在 *Advances in Neural Information Processing Systems, (NIPS)*, 2016 年。
- [17] 武卡斯·凯撒和伊利亚·苏茨克维尔。神经 GPU 学习算法。在 *International Conference on Learning Representations (ICLR)*, 2016 年。
- [18] Nal Kalchbrenner, Lasse Espeholt, Karen Simonyan, Aaron van den Oord, Alex Graves 和 Koray Kavukcuoglu。线性时间内的神经机器翻译。 *arXiv preprint arXiv:1610.10099v2*, 2017 年。
- [19] Yoon Kim, Carl Denton, Luong Hoang 和 Alexander M. Rush。结构化注意力网络。在 *International Conference on Learning Representations*, 2017 年。
- [20] 迪德里克·金马和吉米·巴。Adam: 一种随机优化方法。 *ICLR*, 2015 年。[21] Oleksii Kuchaiev 和 Boris Ginsburg。LSTM 网络的因式分解技巧。 *arXiv preprint arXiv:1703.10722*, 2017 年。
- [22] 林周涵, 冯敏伟, 西塞罗·诺盖拉·多斯桑托斯, 莫宇, 项兵, 周博文, 约书亚·本吉奥。结构化的自我关注句子嵌入。 *arXiv preprint arXiv:1703.03130*, 2017 年。
- [23] Minh-Thang Luong, Quoc V. Le, Ilya Sutskever, Oriol Vinyals 和 Lukasz Kaiser。多任务序列到序列学习。 *arXiv preprint arXiv:1511.06114*, 2015。
- [24] Minh-Thang Luong, Hieu Pham 和 Christopher D Manning。基于注意力的神经机器翻译的有效方法。 *arXiv preprint arXiv:1508.04025*, 2015。

- [25] 米切尔·P·马库斯、玛丽·安·马尔辛凯维奇和比阿特丽斯·圣托里尼。建立一个大型带注释的英语语料库：宾夕法尼亚树库。 *Computational linguistics*, 19(2): 313–330, 1993。
- [26] 大卫·麦克洛斯基、尤金·查尼亚克和马克·约翰逊。有效的解析自我训练。在 *Proceedings of the Human Language Technology Conference of the NAACL, Main Conference* 中, 第 152-159 页。ACL, 2006 年 6 月。
- [27] Ankur Parikh、Oscar Täckström、Dipanjan Das 和 Jakob Uszkoreit。可分解的注意力模型。在 *Empirical Methods in Natural Language Processing*, 2016 年。
- [28] 罗曼·保卢斯, 蔡明熊, 理查德·索彻。用于抽象概括的深度强化模型。 *arXiv preprint arXiv:1705.04304*, 2017。
- [29] 斯拉夫·彼得罗夫、莱昂·巴雷特、罗曼·蒂博和丹·克莱因。学习准确、紧凑且可解释的树注释。在 *Proceedings of the 21st International Conference on Computational Linguistics and 44th Annual Meeting of the ACL*, 第 433-440 页。ACL, 2006 年 7 月。
- [30] 奥菲尔出版社和利奥尔·沃尔夫。使用输出嵌入来改进语言模型。 *arXiv preprint arXiv:1608.05859*, 2016。
- [31] Rico Sennrich、Barry Haddow 和 Alexandra Birch。具有子词单元的稀有词的神经机器翻译。 *arXiv preprint arXiv:1508.07909*, 2015。
- [32] 诺姆·沙泽尔、阿扎利亚·米尔霍塞尼、克日什托夫·马齐亚兹、安迪·戴维斯、夸克·勒、杰弗里·辛顿和杰夫·迪恩。极其庞大的神经网络：稀疏门控的专家混合层。 *arXiv preprint arXiv:1701.06538*, 2017 年。
- [33] Nitish Srivastava、Geoffrey E Hinton、Alex Krizhevsky、Ilya Sutskever 和 Ruslan Salakhutdinov。Dropout: 防止神经网络过度拟合的简单方法。 *Journal of Machine Learning Research*, 15(1): 1929–1958, 2014。
- [34] Sainbayar Sukhbaatar、Arthur Szlam、Jason Weston 和 Rob Fergus。端到端内存网络。载于 C. Cortes、N. D. Lawrence、D. D. Lee、M. Sugiyama 和 R. Garnett, 编辑, *Advances in Neural Information Processing Systems 28*, 第 2440-2448 页。Curran Associates, Inc., 2015。
- [35] Ilya Sutskever、Oriol Vinyals 和 Quoc VV Le。使用神经网络进行序列到序列学习。 *Advances in Neural Information Processing Systems*, 第 3104-3112 页, 2014 年。
- [36] Christian Szegedy、Vincent Vanhoucke、Sergey Ioffe、Jonathon Shlens 和 Zbigniew Wojna。重新思考计算机视觉的初始架构。 *CoRR*, abs/1512.00567, 2015。
- [37] Vinyals 和 Kaiser、Koo、Petrov、Sutskever 和 Hinton。作为外语的语法。在 *Advances in Neural Information Processing Systems*, 2015 年。
- [38] 吴永辉, Mike Schuster, 陈志峰, Quoc V Le, Mohammad Norouzi, Wolfgang Macherey, Maxim Krikun, 曹元, 高勤, Klaus Macherey, 等。谷歌的神经机器翻译系统: 弥合人类和机器翻译之间的差距。 *arXiv preprint arXiv:1609.08144*, 2016 年。
- [39] 周杰, 曹英, 王旭光, 李鹏, 徐伟。具有用于神经机器翻译的快速连接的深度循环模型。 *CoRR*, abs/1606.04199, 2016。
- [40] 朱慕华, 张悦, 陈文良, 张敏, 朱静波。快速准确的移位归约成分解析。在 *Proceedings of the 51st Annual Meeting of the ACL (Volume 1: Long Papers)*, 第 434-443 页。ACL, 2013 年 8 月。

Attention Visualizations




图3: 第5层(共6层)中编码器自注意力中的长距离依赖关系的注意力机制示例。许多注意力头关注动词“making”的远距离依赖,从而完成短语“making...more困难”。这里仅显示“制作”一词的注意事项。不同的颜色代表不同的头。最好以彩色形式观看。




图4：两个注意力头，也在第6层的第5层，显然参与了照应解析。顶部：头部5的完整注意力。底部：注意力头部5和6的注意力与单词“its”隔离。请注意，该单词的注意力非常尖锐。




图 5: 许多注意力头表现出的行为似乎与句子的结构相关。我们在上面给出了两个这样的例子，来自第 5 层或第 6 层编码器自注意力的两个不同的头。这些头显然学会了执行不同的任务。